

به نام خدا

تحلیل احساس کاربران درباره ی محصولات دیجیتال

با استفاده از وب اسکرپینگ و یادگیری ماشین

نام و نام خانوادگی و شماره دانشجویی:

امیرحسین رضایی 403541474

استاد: دکتر رفیعی

تاریخ تحویل پروژه: 1404/05/27

نیمسال دوم 1403-1404

دانشگاه علم و صنعت ایران

مهندسی کامپیوتر



فهرست مطالب

3	مقدمه
4	روش کار (گزارش گام به گام)
4	استخراج داده‌ها Web Scraping
6	پاکسازی متن (Text Preprocessing)
8	بردارسازی متن (Vectorization)
9	مدلسازی و ارزیابی نتایج
11	تحلیل نتایج مدل‌ها
12	جمع‌بندی
13	نمودارها

توضیح کلی پروژه و اهمیت آن

این پروژه را با هدف تحلیل احساسات کاربران دربارهٔ محصولات دیجیتال انجام دادیم. امروزه کاربران نظرات خود را در سایت‌های فروشگاهی و پلتفرم‌های نقد و بررسی می‌گذارند و این نظرات پر از اطلاعات ارزشمند مثل میزان رضایت، کیفیت محصول یا نیازهای پنهان کاربران—هستند. اهمیت پروژه در آن است که با استفاده از پایتون، وب‌اسکرپینگ و مدل‌های ساده یادگیری ماشین، می‌توانیم این احساسات را به صورت خودکار استخراج و دسته‌بندی کنیم. انجام این پروژه باعث شد مهارت عملی‌مان در وب‌اسکرپینگ، پردازش داده‌های متنی و ساخت مدل‌های یادگیری ماشین بالا برود.

تعریف مسئله: چرا طبقه‌بندی احساسات مهم است؟

با توجه به حجم بالای نظرات کاربران در فضای وب، بررسی دستی آن‌ها کاری زمان‌بر و غیرعملی است. طبقه‌بندی خودکار احساسات به ما کمک می‌کند تا سریع‌تر بفهمیم کاربران از محصولات رضایت دارند یا خیر، مشکلات احتمالی را شناسایی کنیم و تصمیمات بهتری برای بهبود محصول یا خدمات بگیریم.

معرفی مراحل پروژه به زبان ساده

جمع‌آوری نظرات کاربران از یک یا چند وب‌سایت با استفاده از وب‌اسکرپینگ

پردازش و آماده‌سازی متن‌ها برای مدلسازی (پاکسازی، نرمال‌سازی و استخراج ویژگی‌ها)

آموزش یک مدل یادگیری ماشین برای تشخیص احساسات مثبت یا منفی نظرات

ارزیابی عملکرد مدل و تحلیل نتایج به صورت نموداری و عددی

روش کار (گزارش گام به گام)

Web Scraping استخراج داده‌ها

در این پروژه، برای جمع‌آوری نظرات کاربران ابتدا سایت‌های مختلفی بررسی شدند. در این پروژه، **Trustpilot** طاقچه، باسلام و :جمع‌آوری داده‌ها از سه وبسایت مختلف انجام شد. مسئولیت بخش وب‌اسکرپینگ را **امیرحسین رضایی** بر عهده داشت و تمامی مراحل استخراج داده‌ها از وبسایت‌ها توسط وی انجام شد.

ابتدا طاقچه‌انتخاب شد، زیرا ساختار ساده‌ای داشت و تنها با یک کلیک می‌توانستیم به صفحه نظرات دسترسی پیدا کنیم که استخراج نظرات را آسان می‌کرد. با این حال، نظرات موجود در طاقچه بیشتر شامل خلاصه یا بخش‌هایی از کتاب‌ها بود و نظرات صریح درباره کیفیت کتاب‌ها بسیار محدود بود.

برای دسترسی به نظرات صریح‌تر، به سراغ سایت‌های فروشگاهی رفتیم و پس از بررسی گزینه‌هایی مانند دیجی‌کالا، ترب، خانومی و تکنولایف، سایت باسلام به عنوان گزینه مناسب انتخاب شد. نظرات در باسلام کیفیت بهتری داشت و تحلیل آن‌ها نتیجه بهتری داشت، اما زمان دریافت نظرات بیشتر بود؛ زیرا در مودال باز شده، نظرات پس از هر اسکرول 650 پیکسلی بارگذاری می‌شدند و در هر مرحله تنها 6 تا 8 نظر اضافه می‌شد که باعث افزایش زمان استخراج شد.

ساختار نظرات در باسلام به صورت زیر بود:

بود 'RsmRPU' هر بخش شامل 6 نظر با کلاس -

منحصر به فرد 'id' و دارای یک 'MJ3_KD eN63l8 _9ltxo8 VqUuAS' هر نظر در کلاس -
'review-20097509' بود، مانند

هر نظر شامل دو دیو درونی بود -

'm7EJHG' و دیو داخلی 'Ee9yOO' یک دیو شامل نام کاربر و ستاره‌ها با کلاس -

و ستاره‌ها ('Rqze5j')، نام کاربر ('eN4XZm') تاریخ نظر 'UxGx9M' در کلاس -
قرار داشت ('_4rePWQ')

``bs-rating__star bs-rating__star--active bs-rating__star--readonly``: ستاره‌های توپر -

``bs-rating__star bs-rating__star--readonly``: ستاره‌های توخالی -

``bs-button bs-button--sm bs-button--outline bs-button--outline-secondary`` و در دیو `I63B8n`` قرار داشت. برای مشاهده نظرات بیشتر، باید روی کلید "مشاهده تجربه خریدها" کلیک می‌کردیم که در کلاس

استفاده شد و کد اصلی شامل مراحل زیر Pandas و Selenium برای استخراج نظرات، از کتابخانه‌های بود:

1. باز کردن صفحه محصول و کلیک روی دکمه مودال نظرات

2. یافتن عنصر اسکرولر در مودال و اسکرول مرحله‌ای

3. جمع‌آوری نظرات جدید و ذخیره آن‌ها در DataFrame

4. خروجی نهایی به صورت فایل CSV ذخیره شد

پاکسازی متن (Text Preprocessing)

در این مرحله، داده‌های جمع‌آوری شده از وبسایت‌ها توسط محمد امین قدردانی برای تحلیل آماده شدند. پاکسازی متن شامل مراحل زیر بود:

- **نرمال‌سازی متن (Normalization):** یکسان‌سازی حروف و اصلاح قالب‌های نوشتاری.
- **حذف نویزها (Noise Removal):** حذف کاراکترهای غیرضروری و نویزهای موجود در داده‌ها.
- **توکن‌سازی (Tokenization):** تقسیم متن به واحدهای معنی‌دار مانند کلمات یا جملات.
- **حذف کلمات توقف (Stopword Removal):** حذف کلماتی که بار معنایی کمی دارند و تحلیل متن را تحت تأثیر قرار می‌دهند.
- **سازگاری با وردکلاود و تحلیل‌های بصری:** آماده‌سازی داده‌ها برای نمایش گرافیکی و تحلیل‌های تصویری مانند WordCloud.

این مراحل باعث شدند تا داده‌ها برای بردارسازی و مدل‌سازی آماده و قابل اعتماد باشند.

(Normalization) نرمال‌سازی متن

با استفاده از کلاس <نرمالایز> از کتابخانه <هزم> متن فارسی یکپارچه شد.

نمونه تغییرات: یکسان‌سازی شکل‌های مختلف املائی، حذف فاصله‌های اضافی، یکنواخت کردن نیم‌فاصله و حروف.

(Noise Removal) حذف نویزها

(. . . ؟ . ، @ !) حذف علائم نگارشی و نویسه‌های غیرحروفی

حذف اعداد فارسی و انگلیسی

حذف فاصله‌های اضافی بین کلمات

(Tokenization) توکن سازی:

متن به کلمات شکسته شد با استفاده از <توکنایزر> از کتابخانه <هزم>

(Stopword Removal) حذف کلمات توقف:

کلمات رایج و غیرمفید فارسی (مثل: و، در، به، از، که، با و ...) حذف شدند تا تحلیل‌ها روی کلمات مهم‌تر تمرکز داشته باشد.

علاوه بر حذف <استاپ ورد> ها کلمات خیلی کوتاه (یک حرف) نیز حذف شدند

سازگاری با <ورد کلاود> و تحلیل‌های بصری:

نویسه‌های غیرحروفی دوباره فیلتر شدند تا <ورد کلاود> زیبا و بدون نویز تولید شود

بردارسازی متن (Vectorization)

روش استفاده شده:

تا متن‌ها به بردارهای (TfidfVectorizer) استفاده شد **TF-IDF Vectorizer** از عددی تبدیل شوند.

پارامترهای کلیدی:

فقط ۱۰ هزار ویژگی پرتکرارترین کلمات $\rightarrow \text{max_features}=10000$

(bigram) و دوتایی‌ها (unigram) تک‌کلمه‌ای‌ها $\rightarrow \text{ngram_range}=(1, 2)$ لحاظ شدند تا وابستگی‌های کوتاه میان کلمات هم در بردار ثبت شود.

کلمات با فراوانی کمتر از ۲ نادیده گرفته شدند تا نویز کاهش یابد. $\rightarrow \text{min_df}=2$

دلایل انتخاب این روش:

نه تنها فراوانی کلمات را در نظر می‌گیرد، بلکه اهمیت نسبی هر کلمه را در **TF-IDF** متن‌های مختلف وزن‌دهی می‌کند.

مناسب است، زیرا کلمات رایج (Sentiment Analysis) این روش برای تحلیل احساسات اما غیرمهم (مثل «این»، «و») وزن کمی دارند و تأثیرشان در مدل کاهش می‌یابد.

دوکلمه‌ای باعث می‌شود عبارات کوتاه (مثل «خیلی خوب») به درستی n-gram استفاده از ثبت و مدل بتواند معنی‌های جزئی‌تر را یاد بگیرد.

نتیجه:

، MultinomialNB بردارسازی باعث شد داده‌های متنی قابل استفاده برای مدل‌های LogisticRegression ،

شوند و دقت مدل‌ها به میزان قابل توجهی افزایش یابد LinearSVC

مدلسازی و ارزیابی نتایج

برای بخش مدلسازی، سه الگوریتم پرکاربرد در حوزه طبقه‌بندی متن مورد استفاده قرار گرفت:

1. Naive Bayes (MultinomialNB): یک مدل سریع و ساده که اغلب به عنوان خط پایه (Baseline) در مسائل پردازش زبان طبیعی استفاده می‌شود.
2. Logistic Regression: مدلی خطی که در مسائل دودویی (مثل مثبت و منفی) عملکرد بسیار مناسبی دارد.
3. Linear SVM (Support Vector Machine): مدلی قدرتمند برای داده‌های متنی با قابلیت ایجاد مرز تصمیم‌گیری بهینه بین دو دسته.

تنظیمات و آموزش

- برای هر مدل جداگانه (Test) و آزمون (Train) داده‌ها پس از تقسیم به دو بخش آموزش و آموزش داده شدند.
- به عنوان ورودی مدل‌ها استفاده شد (ngram_range=(1,2) و max_features=10000) از TF-IDF بردارسازی.
- تعیین شد تا مدل فرصت کافی max_iter=1000 پارامتر Logistic Regression برای همگرایی داشته باشد.
- سایر تنظیمات مدل‌ها به صورت پیش فرض استفاده شدند.

نتایج ارزیابی

پس از آموزش و تست مدل‌ها، نتایج به دست آمده روی داده‌های آزمون در جدول زیر آمده است:

Accuracy Precision Recall F1-Score (دقت مدل)

Naive Bayes	0.78	0.77	0.80	0.78
Logistic Regression	0.84	0.83	0.85	0.84
Linear SVM (SVC)	0.86	0.85	0.87	0.86




تحلیل نتایج

بهترین عملکرد را در بین مدل‌ها داشته و توانسته است **Linear SVM** همان‌طور که مشخص است، را به‌دست آورد **F1-Score** بالاترین دقت و

ضعیف‌تر بوده **SVM** نیز نتایج قابل قبولی ارائه داده و تنها کمی از **Logistic Regression** مدل است.

در مقایسه با دو مدل دیگر عملکرد پایین‌تری داشت، هرچند همچنان به‌عنوان **Naive Bayes** مدل یک مدل پایه سریع و سبک ارزش بررسی داشت

نمایش ماتریس‌های درهم‌ریختگی هر مدل:



تحلیل نتایج مدل‌ها

و همچنین نمودارهای (Accuracy, Precision, Recall و F1-Score) با توجه به معیارهای ارزیابی: ماتریس درهم‌ریختگی

Naive Bayes

سریع‌ترین مدل در مرحله آموزش و پیش‌بینی بود.

اما دقت آن نسبت به دو مدل دیگر پایین‌تر بود و مخصوصاً در تشخیص نظرات منفی خطاهای بیشتری داشت.

به دلیل سادگی فرضیاتش (استقلال ویژگی‌ها)، در داده‌های واقعی که پیچیدگی بالاتری دارند عملکرد محدودتری نشان داد.

Logistic Regression

تبادل خوبی بین سرعت و دقت داشت.

توانست نظرات مثبت و منفی را نسبتاً دقیق از هم جدا کند.

بود، اما هنوز در برخی نمونه‌های مبهم اشتباه Naive Bayes نسبت به نویز مقاوم‌تر از. داشت

Linear SVM

دقیق‌ترین مدل در میان سه روش بود.

در جداسازی مرز میان داده‌های مثبت و منفی عملکرد بهتری نشان داد و تعداد خطاهای آن حداقل بود.

البته زمان آموزش آن نسبت به دو مدل دیگر بیشتر بود، اما در پیش‌بینی نهایی سرعت قابل‌قبولی داشت.

جمع‌بندی

بهترین عملکرد را داشت SVM: از نظر دقت و پایداری


جمع‌بندی

در این پروژه ما توانستیم یک سامانه‌ی ساده برای تحلیل احساس کاربران نسبت به محصولات دیجیتال طراحی کنیم. ابتدا داده‌ها را از یک وبسایت جمع‌آوری کردیم، سپس آن‌ها را پاک‌سازی و به شکل مناسب برای پردازش زبانی آماده کردیم. پس از آن، با استفاده از روش‌های مختلف بردارسازی و سه مدل یادگیری احساسات موجود در نظرات را به صورت (SVM و Logistic Regression, Naive Bayes) ماشین بالترین دقت را داشته و می‌تواند به SVM مثبت یا منفی طبقه‌بندی کردیم. نتایج نشان داد که مدل عنوان بهترین گزینه در این پروژه در نظر گرفته شود.

در طول مسیر با چالش‌هایی مانند استخراج داده‌های ناسازگار، وجود نویز در متن‌ها، و تنظیم پارامترهای مناسب برای مدل‌ها مواجه شدیم. همچنین مقایسه‌ی سرعت و دقت مدل‌ها و انتخاب روش بهینه برای بردارسازی از جمله مسائلی بود که نیازمند بررسی دقیق‌تر بود.


از نظر آموزشی، این پروژه برای ما تجربه‌ی ارزشمندی در زمینه‌ی کار با ابزارهای وباسکرپینگ، پردازش و مدل‌های یادگیری ماشین فراهم کرد. همچنین توانستیم مهارت خود را در تحلیل (NLP) زبان طبیعی داده، گزارش‌نویسی و کار گروهی تقویت کنیم.

نمودارها



نمودار 1- توزیع احساسات

توزیع درصدی احساسات



مثبت 😊
نمودار 2- توزیع درصدی احساسات

